

Avaliando modelos de linguagem

Trabalhando com Texto em Python I · Unidade 4

CiberExt 26-29 · FEELT38103 · Universidade Federal de Uberlândia

2026

Sumário

1. O que é um padrão-ouro (<i>gold standard</i>)?	1
2. Medindo a confiabilidade manualmente	1
3. O kappa de Cohen como medida de concordância	4
4. Avaliando o desempenho de modelos de linguagem	5
Quiz	9
Resumo da unidade	9

Objetivos de aprendizagem

Ao final desta unidade, você deverá:

- entender o que é um **padrão-ouro** (*gold standard*);
- saber **avaliar a concordância** entre anotadores humanos;
- compreender **métricas simples** para avaliar o desempenho do processamento de linguagem natural.

1. O que é um padrão-ouro (*gold standard*)?

Um **padrão-ouro** (*gold standard*) — também chamado de *ground truth* (“verdade fundamental”) — refere-se a **dados verificados por humanos** que podem ser usados como referência (*benchmark*) para avaliar o desempenho de algoritmos. Em processamento de linguagem natural, os padrões-ouro medem quão bem os **humanos** desempenham uma tarefa.

O objetivo do PLN é permitir que computadores **alcancem ou superem** o desempenho humano em uma tarefa pré-definida. Medir se os algoritmos conseguem isso exige uma referência — e é o padrão-ouro que a fornece. Em termos simples, ele oferece um **ponto de referência**.

É importante entender, porém, que **padrões-ouro são abstrações do uso da língua**. Considere a tarefa de classificar palavras em classes gramaticais: as classes não são dadas pela natureza — elas representam uma abstração que impõe estrutura à língua. A língua, entretanto, é naturalmente **ambígua e subjetiva**, e as abstrações usadas podem ser incompletas: não temos certeza de que todos os usuários classificariam as palavras da mesma forma.

Por isso precisamos **medir a confiabilidade** de qualquer padrão-ouro, ou seja, até que ponto os humanos **concordam** na tarefa.

2. Medindo a confiabilidade manualmente

Esta seção mostra como a **confiabilidade** — geralmente entendida como a **concordância entre múltiplos anotadores** — pode ser medida manualmente.

Passo 1 — Anotar os dados

A **análise de sentimento** é uma tarefa que consiste em determinar o sentimento de um texto. Treinar um modelo de análise de sentimento exige coletar dados de treino, isto é, exemplos de textos associados a diferentes sentimentos.

Classifique os *tweets* a seguir em três categorias — **positivo**, **neutro** ou **negativo** — de acordo com o sentimento. Anote sua decisão (uma por linha), mas **não** discuta nem mostre ao colega ao lado:

1. Updated: HSL GTFS (Helsinki, Finland) <https://t.co/fWEpzmNQLz>
2. current weather in Helsinki: broken clouds, -8°C 100% humidity, wind 4kmh, pressure 1061mb
3. CNN: “WallStreetBets Redditors go ballistic over GameStop’s sinking share price”
4. Baana bicycle counter. Today: 3 Same time last week: 1058 Trend: ↓99% This year: 819 518 Last year: 802 079 #Helsinki #cycling
5. Elon Musk is now tweeting about #bitcoin
6. A perfect Sunday walk in the woods just a few steps from home.
7. Went to Domino’s today It was so amazing and I think I got damn good dessert as well. . .
8. Choo Choo There’s our train! #holidayahead
9. Happy women’s day kisses to all you beautiful ladies. #awesometobeawoman
10. Good morning #Helsinki! Sun will rise in 30 minutes (local time 07:28)

Anote suas classificações (uma por linha, de 1 a 10). O colega ao lado faz o mesmo, de forma independente — assim teremos **dois anotadores** para comparar.

Passo 2 — Calcular a concordância percentual

Ao criar conjuntos de dados para treinar modelos, geralmente queremos que os dados sejam **confiáveis**, ou seja, que haja concordância sobre o que descrevemos (aqui, o sentimento dos *tweets*).

Uma forma de medir isso é a **concordância percentual** simples: quantas vezes, das 10, você e o colega concordaram. Basta dividir o número de concordâncias pelo número de itens (10):

```
# Substitua o numero abaixo pelo numero de itens em que voces concordaram
agreement = 0

# Divide a contagem pelo numero de tweets
agreement = agreement / 10

# Imprime a variavel
agreement
```

```
0.0
```

Passo 3 — Calcular as probabilidades de cada categoria

A concordância percentual é, na verdade, uma medida **muito ruim**: qualquer um dos dois pode ter **acertado por sorte** — ou ter achado a tarefa tediosa e classificado tudo aleatoriamente. Se isso aconteceu, a concordância percentual **não tem como detectar**, pois ela não distingue acerto real de acaso!

Felizmente, dá para estimar a possibilidade de **concordância por acaso**. O primeiro passo é contar quantas vezes **você** usou cada categoria e converter essas contagens em **probabilidades**, dividindo pelo total de *tweets*:

```
# Conte quantos itens *voce* colocou em cada categoria
positive = 0
neutral = 0
negative = 0

# Converte as contagens em probabilidades
positive = positive / 10
neutral = neutral / 10
negative = negative / 10

# Chama cada variavel para examinar a saida
positive, neutral, negative
```

```
(0.0, 0.0, 0.0)
```

Essas probabilidades representam a chance de **você** escolher aquela categoria. Agora pergunte ao colega as probabilidades dele e registre-as:

```
nb_positive = 0
nb_neutral = 0
nb_negative = 0
```

Conhecendo as probabilidades de cada classe para os **dois** anotadores, podemos calcular a probabilidade de ambos escolherem a mesma categoria **por acaso**. Para cada categoria, basta multiplicar a sua probabilidade pela do colega:

```
both_positive = positive * nb_positive
both_neutral = neutral * nb_neutral
both_negative = negative * nb_negative
```

Nota: se um anotador não colocou nenhum *tweet* em uma categoria (por exemplo, *negative*) e o outro colocou, isso **anula** a chance de concordância por acaso naquela categoria — multiplicar por zero resulta em zero.

Passo 4 — Estimar a concordância esperada (por acaso)

Agora podemos calcular quão provável é concordar **por acaso**. Isso é a **concordância esperada** (*expected agreement*), obtida somando as probabilidades combinadas de cada categoria:

```
expected_agreement = both_positive + both_neutral + both_negative

expected_agreement
```

```
0.0
```

Conhecendo tanto a **concordância observada** (*agreement*) quanto a **esperada por acaso** (*expected_agreement*), podemos usar uma medida mais confiável: o **kappa de Cohen** (κ), que estima a concordância a partir de ambas. A fórmula é:

$$\kappa = \frac{P_{\text{observado}} - P_{\text{esperado}}}{1 - P_{\text{esperado}}}$$

Como essa informação já está nas variáveis `agreement` e `expected_agreement`, calculamos κ facilmente. Note que envolvemos as subtrações em **parênteses** para executá-las antes da divisão:

```
kappa = (agreement - expected_agreement) / (1 - expected_agreement)

kappa

0.0
```

3. O kappa de Cohen como medida de concordância

O valor teórico do κ de Cohen vai de **-1** (discordância perfeita) a **+1** (concordância perfeita), com **0** indicando concordância totalmente aleatória. O κ costuma ser interpretado como uma medida da **força** da concordância.

Landis e Koch (1977) propuseram os *benchmarks* abaixo — que devem ser levados **com cautela**, pois as divisões são arbitrárias:

Kappa de Cohen (κ)	Força da concordância
< 0,00	Pobre
0,00 – 0,20	Ligeira
0,21 – 0,40	Razoável
0,41 – 0,60	Moderada
0,61 – 0,80	Substancial
0,81 – 1,00	Quase perfeita

O κ de Cohen serve para medir a concordância entre **dois** anotadores, e as categorias disponíveis devem ser fixadas de antemão. Para mais de dois anotadores, usa-se uma medida como o κ **de Fleiss**.

Na prática, o κ de Cohen (e muitas outras medidas) já está implementado em bibliotecas Python — raramente é preciso calcular à mão. A biblioteca **scikit-learn** (`sklearn`), por exemplo, inclui a função `cohen_kappa_score()`, que recebe **duas listas** e calcula o κ entre elas:

```
# Importa a funcao cohen_kappa_score do modulo 'metrics' da scikit-learn
from sklearn.metrics import cohen_kappa_score

# Define duas listas, 'a1' e 'a2', com anotacoes de classes gramaticais
a1 = ['ADJ', 'AUX', 'NOUN', 'VERB', 'VERB']
a2 = ['ADJ', 'VERB', 'NOUN', 'NOUN', 'VERB']

# Usa cohen_kappa_score() para calcular a concordancia entre as listas
cohen_kappa_score(a1, a2)

0.444444444444444453
```

Segundo o *benchmark* de Landis e Koch, esse valor indicaria concordância **moderada**.

Dica: raramente é preciso anotar o conjunto inteiro para medir a concordância — uma **amostra aleatória** costuma bastar. Se o κ sugere que os anotadores concordam, assumimos que as anotações são confiáveis (não aleatórias). Ainda assim, toda medida de concordância entre anotadores depende de suas próprias suposições sobre o que é “concordar” — nenhuma representa a verdade absoluta.

4. Avaliando o desempenho de modelos de linguagem

Com um padrão-ouro suficientemente confiável, podemos usá-lo para medir o desempenho de modelos de linguagem. Suponha um padrão-ouro com 10 tokens anotados por classe gramatical, na lista `gold_standard`, e as previsões de um modelo na lista `predictions`:

```
# Define a lista 'gold_standard' (padrao-ouro anotado por humanos)
gold_standard = ['ADJ', 'ADJ', 'AUX', 'VERB', 'AUX', 'NOUN', 'NOUN', 'ADJ', 'DET', 'PRON']

# Define a lista 'predictions' (previsoes do modelo de linguagem)
predictions = ['NOUN', 'ADJ', 'AUX', 'VERB', 'AUX', 'NOUN', 'VERB', 'ADJ', 'DET', 'PROPN']
```

4.1 Acurácia

Vamos importar o módulo `metrics` inteiro da scikit-learn. A função `accuracy_score()` calcula a **acurácia**, que é exatamente a mesma coisa que a concordância observada calculada manualmente:

```
# Importa o modulo 'metrics' da biblioteca scikit-learn (sklearn)
from sklearn import metrics

# Usa a funcao accuracy_score() do modulo 'metrics'
metrics.accuracy_score(gold_standard, predictions)
```

0.7

A acurácia sofre do mesmo problema da concordância observada — pode ser resultado de **palpites de sorte**. Como é um exemplo pequeno, dá para verificar que **7 de 10** classes gramaticais coincidem, resultando em acurácia de 0,7 (70%).

4.2 Matriz de confusão

Para avaliar melhor o modelo, organizamos os resultados em uma **matriz de confusão**. Precisamos de todas as classes gramaticais que aparecem em `gold_standard` e `predictions`. Coletamos as categorias únicas com a função `set()` — um **conjunto** (*set*) é uma estrutura do Python com itens únicos, útil aqui para remover duplicatas:

```
# Coleta as classes gramaticais unicas em um conjunto, combinando as duas listas
pos_tags = set(gold_standard + predictions)

# Ordena o conjunto alfabeticamente e converte o resultado em lista
pos_tags = list(sorted(pos_tags))

# Imprime a lista resultante
pos_tags
```

```
['ADJ', 'AUX', 'DET', 'NOUN', 'PRON', 'PROPN', 'VERB']
```

Usamos essas categorias para montar uma tabela em que as **linhas** representam o padrão-ouro e as **colunas** as previsões do modelo. Percorremos cada par de itens (padrão-ouro, previsão) e somamos **+1** na célula correspondente. Por exemplo, o primeiro item de `gold_standard` é `ADJ` e o primeiro de `predictions` é `NOUN`:

```
# Imprime o primeiro item de cada lista
gold_standard[0], predictions[0]
```

```
('ADJ', 'NOUN')
```

Encontramos a linha `ADJ` e a coluna `NOUN` e somamos 1 àquela célula. A tabela completa (a **matriz de confusão**) fica assim:

	ADJ	AUX	DET	NOUN	PRON	PROPN	VERB
ADJ	2	0	0	1	0	0	0
AUX	0	2	0	0	0	0	0
DET	0	0	1	0	0	0	0
NOUN	0	0	0	1	0	0	1
PRON	0	0	0	0	0	1	0
PROPN	0	0	0	0	0	0	0
VERB	0	0	0	0	0	0	1


As previsões corretas formam uma **linha aproximadamente diagonal** na tabela. A partir dela, derivamos duas métricas por classe: **precisão** (*precision*) e **revocação** (*recall*).

- **Precisão** é a proporção de previsões corretas **por classe** — quantas das previsões daquela classe estavam certas. Por exemplo, a coluna `VERB` soma **2**, mas só **1** previsão está correta (na linha `VERB`); logo, a precisão de `VERB` é $1/2 = 0,5$. O mesmo vale para `NOUN`.
- **Revocação** é a proporção de previsões corretas dentre **todos os exemplos reais** daquela classe — quantas instâncias reais o modelo conseguiu “encontrar”. Por exemplo, a linha `ADJ` soma **3** (há três adjetivos no padrão-ouro), mas só **2** estão na coluna `ADJ`; logo, a revocação de `ADJ` é $2/3 \approx 0,66$. Para `NOUN`, a revocação é $1/2 = 0,5$.

A scikit-learn gera matrizes de confusão automaticamente com `confusion_matrix()`:

```
# Calcula a matriz de confusao para as duas listas e imprime o resultado
print(metrics.confusion_matrix(gold_standard, predictions))
```

```
[[2 0 0 1 0 0 0]
 [0 2 0 0 0 0 0]
 [0 0 1 0 0 0 0]
 [0 0 0 1 0 0 1]
 [0 0 0 0 0 1 0]
 [0 0 0 0 0 0 0]
 [0 0 0 0 0 0 1]]
```



$$\text{Precisão} = \text{VP} / (\text{VP} + \text{FP})$$

$$\text{Revocação} = \text{VP} / (\text{VP} + \text{FN})$$

Figura 1: Precisão e revocação: os **relevantes** são o padrão-ouro; os **recuperados** são as previsões do modelo. A **precisão** olha para os recuperados (quantos acertou); a **revocação** olha para os relevantes (quantos encontrou).

4.3 Precisão e revocação com a scikit-learn

A **precisão** é implementada na função `precision_score()`. Como temos **mais de duas** classes, precisamos definir como os resultados de cada classe são combinados, pelo argumento `average`. Com `average=None`, a função calcula a precisão **de cada classe**. Também definimos `zero_division=0` para evitar erro quando uma classe de `predictions` não existe em `gold_standard` (nesses casos, a precisão é 0):

```
# Calcula a precisao entre as duas listas, para cada classe (classe gramatical)
precision = metrics.precision_score(gold_standard, predictions, average=None,
    ↪ zero_division=0)
```

```
# Chama a variavel para examinar o resultado
precision
```

```
array([1. , 1. , 1. , 0.5, 0. , 0. , 0.5])
```

A saída é um **array NumPy**. Para combinar os rótulos de `pos_tags` com as pontuações de `precision`, usamos a função `zip()`, que une listas/arrays do mesmo tamanho; para visualizar, convertamos com `dict()`:

```
# Combina o conjunto 'pos_tags' com o array 'precision' usando zip();
# converte o resultado em um dicionario
dict(zip(pos_tags, precision))
```

```
{'ADJ': 1.0, 'AUX': 1.0, 'DET': 1.0, 'NOUN': 0.5, 'PRON': 0.0, 'PROPN': 0.0, 'VERB': 0.5}
```

Para uma **única** pontuação de precisão para todas as classes, usamos `average='macro'`, que trata cada classe como igualmente importante, independentemente de quantas instâncias ela tem:

```
# Calcula a precisao entre as duas listas e tira a media (macro)
macro_precision = metrics.precision_score(gold_standard, predictions, average='macro',
    ↪ zero_division=0)

# Chama a variavel para examinar o resultado
macro_precision
```

```
0.5714285714285714
```

A precisão **macro** é a soma das precisões dividida pelo número de classes — dá para verificar manualmente:

```
# Calcula a media macro manualmente: soma as precisoes e divide
# pelo numero de classes em 'precision'
sum(precision) / len(precision)
```

```
0.5714285714285714
```

A **revocação** é calculada do mesmo modo, com `recall_score()`:

```
# Calcula a revocacao entre as duas listas, para cada classe
recall = metrics.recall_score(gold_standard, predictions, average=None, zero_division=0)

# Combina 'pos_tags' com o array 'recall' e converte em dicionario
dict(zip(pos_tags, recall))
```

```
{'ADJ': 0.6666666666666666, 'AUX': 1.0, 'DET': 1.0, 'NOUN': 0.5, 'PRON': 0.0, 'PROPN':
    ↪ 0.0, 'VERB': 1.0}
```

4.4 Relatório de classificação

A scikit-learn oferece a função `classification_report()`, que dá precisão e revocação de cada classe, junto com o **F1-score** — uma média equilibrada entre precisão e revocação (ambas contribuem igualmente), variando de 0 a 1:

```
# Imprime um relatorio de classificacao
print(metrics.classification_report(gold_standard, predictions, zero_division=0))
```

	precision	recall	f1-score	support
ADJ	1.00	0.67	0.80	3
AUX	1.00	1.00	1.00	2
DET	1.00	1.00	1.00	1
NOUN	0.50	0.50	0.50	2
PRON	0.00	0.00	0.00	1
PROPN	0.00	0.00	0.00	0
VERB	0.50	1.00	0.67	1
accuracy			0.70	10
macro avg	0.57	0.60	0.57	10

weighted avg	0.75	0.70	0.71	10
--------------	------	------	------	----

As pontuações da linha **macro avg** correspondem às que calculamos acima. A linha **weighted avg** (média ponderada) leva em conta o número de instâncias de cada classe; a coluna **support** conta quantas instâncias foram observadas em cada classe.

Quiz

Marque a alternativa correta (a resposta certa está destacada com ✓).

1. Um padrão-ouro (*gold standard*) é:

1. Dados verificados por humanos, usados como referência ✓
2. A saída bruta do modelo
3. Um dicionário do Python

2. Por que a concordância percentual é uma medida fraca?

1. Não distingue acerto real de acerto por acaso ✓
2. É difícil de calcular
3. Só funciona com duas classes

3. O kappa de Cohen mede a concordância entre quantos anotadores?

1. Dois ✓
2. Três
3. Qualquer número

4. A precisão de uma classe responde: das vezes em que o modelo *previu* essa classe,

1. quantas estavam certas ✓
2. quantas existiam no total
3. quantas ele deixou de encontrar

5. A revocação de uma classe responde: dos exemplos que *realmente* são dessa classe,

1. quantos o modelo encontrou ✓
2. quantos ele previu a mais
3. quantos estavam errados

6. O F1-score é:

1. A média equilibrada entre precisão e revocação ✓
2. A soma da precisão com a revocação
3. O maior valor entre os dois

Resumo da unidade

Nesta unidade, você aprendeu a:

1. entender o que é um **padrão-ouro** e por que ele é uma **abstração** do uso da língua;
2. medir a **confiabilidade** entre anotadores: concordância percentual, probabilidades por categoria e concordância esperada por acaso;

3. calcular e interpretar o **kappa de Cohen** (manualmente e com `cohen_kappa_score()`), usando os *benchmarks* de Landis & Koch;
4. avaliar o desempenho de modelos com **acurácia, matriz de confusão, precisão, revocação e F1-score**, usando a `scikit-learn` (`accuracy_score`, `confusion_matrix`, `precision_score`, `recall_score`, `classification_report`).

Exercícios sugeridos

1. Anote você mesmo os 10 *tweets* e peça a um colega que faça o mesmo; calcule a concordância percentual e o κ de Cohen com `cohen_kappa_score()`.
 2. Monte suas próprias listas `gold_standard` e `predictions` (com pelo menos 8 itens) e gere a matriz de confusão com `confusion_matrix()`.
 3. A partir do relatório de classificação, explique por que a classe `PROPN` tem `support` igual a 0 e o que isso significa.
 4. Calcule o F1-score de `VERB` **manualmente** a partir da precisão e da revocação (fórmula: $F1 = 2 \cdot (P \cdot R) / (P + R)$) e compare com o relatório.
-

Referências

- Rognvaldsson, E. et al. *Applied Language Technology* (MOOC). Universidade de Helsinque. <https://applied-language-technology.mooc.fi/>
- Landis, J. R.; Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*. <https://scikit-learn.org/>